

Gestión estratégica del talento mediante análisis predictivos: Un marco integrado que combina la matriz de Odiorne y el cuadro de mando integral

Alan Cartes Fica
Facultada de Ciencias Empresariales
Universidad del Bio Bio – Chillán – Chile
alancartes@outlook.com

Resumen — En el contexto actual de alta competitividad organizacional, la retención del talento se ha transformado en un factor estratégico crítico. Esta investigación propone un modelo híbrido e innovador que integra marcos conceptuales clásicos — como la Matriz de Odiorne y el Cuadro de Mando Integral (CMI) — con técnicas avanzadas de analítica predictiva basadas en Machine Learning. El objetivo principal del estudio es diseñar y validar un sistema que permita clasificar estratégicamente a los empleados, segmentar perfiles actitudinales y predecir el riesgo de rotación, con el fin de anticipar decisiones de gestión del talento basadas en evidencia. Mediante el análisis de un dataset estructurado (IBM HR Analytics), se construyó un modelo predictivo de rotación utilizando Random Forest, alcanzando una precisión del 82% y un AUC de 0.79. Además, se aplicaron técnicas de clustering y Análisis de Componentes Principales (PCA) para identificar perfiles latentes de riesgo, que luego se cruzaron con los cuadrantes de la Matriz de Odiorne, generando así un sistema de alerta temprana individualizado. Los resultados revelan patrones consistentes de rotación asociados a sobrecarga laboral, bajo ingreso y menor edad, así como la detección de casos críticos de fuga en empleados de alto valor estratégico. El aporte distintivo de este estudio reside en su capacidad para convertir marcos teóricos en herramientas operativas de decisión, escalables y replicables en distintos contextos. La propuesta metodológica proporciona una plataforma sólida para transformar la gestión del talento en una función predictiva, segmentada y alineada con los objetivos estratégicos de la organización. a.

Palabras Claves — Gestión del talento, cuadro de mando integral, análisis predictivo, aprendizaje automático.

I. INTRODUCCIÓN

En el dinámico entorno empresarial actual, la gestión estratégica del talento se ha convertido en un pilar fundamental para alcanzar ventajas competitivas sostenibles. La capacidad de una organización para atraer, desarrollar y retener a empleados clave no solo influye en su desempeño operativo, sino que también impacta directamente en su posición en el mercado (Al Ariss, Cascio & Paauwe, 2014). Sin embargo, muchas empresas aún enfrentan desafíos al alinear eficazmente sus prácticas de gestión del talento con sus objetivos estratégicos (Makram, Sparrow & Greasley, 2017).

La Matriz de Odiorne, introducida en la década de 1980, ofrece un marco conceptual que clasifica a los empleados según su rendimiento y su potencial, facilitando decisiones informadas sobre desarrollo, movilidad interna y sucesión. Paralelamente, el Cuadro de Mando Integral (Kaplan & Norton, 1992) ha sido ampliamente adoptado para traducir la estrategia organizacional

en objetivos e indicadores medibles a través de diversas perspectivas: financiera, del cliente, de procesos internos y de aprendizaje y crecimiento.

Ambos marcos han demostrado ser útiles en sus respectivos dominios, pero su integración ha sido escasamente explorada en la literatura. A esta situación se suma la creciente disponibilidad de datos y herramientas de analítica predictiva, las cuales han permitido a las organizaciones anticipar comportamientos críticos como la rotación de personal, los niveles de compromiso o la propensión al abandono. La analítica avanzada en recursos humanos (HR analytics) emerge así como un puente entre la intuición gerencial y la toma de decisiones basada en evidencia (TechFunnel, 2024).

En este contexto, surge la oportunidad de construir un modelo híbrido que fusione lo mejor del análisis clásico y la inteligencia artificial aplicada, integrando la Matriz de Odiorne, el Cuadro de Mando Integral y la analítica predictiva para transformar la forma en que se gestiona el talento desde una perspectiva estratégica.

En el entorno organizacional contemporáneo, marcado por una creciente volatilidad del mercado laboral, la retención del talento ha adquirido un rol estratégico esencial. Las organizaciones enfrentan un doble desafío: por un lado, identificar con precisión a los colaboradores clave y, por otro, anticipar la posibilidad de su salida voluntaria. Frente a este panorama, la integración entre herramientas clásicas de evaluación del talento, como la Matriz de Odiorne, y marcos de gestión estratégica como el Cuadro de Mando Integral (CMI), con tecnologías analíticas emergentes, representa una oportunidad de innovación en la toma de decisiones de Recursos Humanos (RR.HH.).

En este contexto, la presente investigación se propone responder a la siguiente pregunta:

¿De qué manera la integración de modelos estratégicos clásicos de gestión del talento (como la Matriz de Odiorne y el Cuadro de Mando Integral) con herramientas de analítica predictiva basada en machine learning puede mejorar la anticipación y toma de decisiones sobre la rotación de personal en contextos organizacionales complejos?

Esta pregunta guía el desarrollo de un modelo híbrido que combina evaluación estratégica, segmentación actitudinal y predicción de riesgo individual de rotación, con el fin de construir un sistema de alerta temprana aplicable en entornos reales. A través de un estudio empírico basado en datos estructurados de empleados (IBM HR Analytics), se busca

demostrar que esta convergencia metodológica permite una lectura más rica y operativa del comportamiento organizacional, y habilita una gestión del talento basada en evidencia, alineada con la estrategia organizacional.

II. MARCO TEÓRICO

La gestión del talento ha dejado de ser una función meramente operativa para convertirse en un componente central de la estrategia organizacional. En un contexto donde la retención del capital humano se ha vuelto crítica, la integración entre enfoques clásicos de clasificación del talento y herramientas de analítica avanzada permite construir sistemas inteligentes de apoyo a la toma de decisiones. Este marco teórico aborda los fundamentos conceptuales que sustentan la investigación, organizados en cuatro pilares: la Matriz de Odiorne, la Analítica de Recursos Humanos, el Cuadro de Mando Integral (CMI) y la Segmentación estratégica de perfiles mediante clustering.

2.1. Matriz de Odiorne

La Matriz de Odiorne (1984) constituye una herramienta clásica de evaluación del talento, basada en dos dimensiones clave: el desempeño actual del colaborador y su potencial de desarrollo futuro. A partir de estos ejes, se generan cuatro cuadrantes: Estrella, Empleado al límite, Empleado problema y Prescindible. Este modelo permite orientar decisiones sobre promoción, formación, retención y desvinculación de manera estratégica, facilitando la asignación eficiente de recursos organizacionales.

No obstante, en contextos contemporáneos caracterizados por alta rotación, estructuras planas y volatilidad laboral, la utilidad de la Matriz de Odiorne puede ser limitada si no se complementa con herramientas analíticas capaces de capturar dinámicas actitudinales, emocionales y conductuales. Por ello, diversos autores han propuesto enriquecer esta herramienta con modelos de datos y segmentación avanzada (Nijs et al., 2022), como parte de una evolución hacia una “Matriz Odiorne 4.0”, numeración que toma sentido al relacionarla con el grado evolutivo dentro del la industria 4.0.



Su aplicación permite segmentar a los empleados en cuadrantes que orientan decisiones sobre retención, formación o desvinculación, convirtiéndola en una herramienta de apoyo a la dirección estratégica del capital humano.

2.2. Analítica de Recursos Humanos

La analítica de recursos humanos representa la aplicación de técnicas estadísticas, minería de datos y aprendizaje automático a información sobre empleados, con el objetivo de apoyar la toma de decisiones basada en evidencia. Según Marler y Boudreau (2017), HR Analytics ha evolucionado desde reportes descriptivos hacia modelos predictivos y prescriptivos, transformando el rol tradicional de RR.HH. en un socio estratégico del negocio.

Particularmente en el análisis de rotación voluntaria, la aplicación de algoritmos como Random Forest o XGBoost ha demostrado alta eficacia en la predicción de salidas, permitiendo la creación de sistemas de alerta temprana (Kim et al., 2020). Estas herramientas permiten identificar con anticipación qué empleados tienen mayor probabilidad de renunciar, cuáles son sus características comunes y qué intervenciones específicas podrían implementarse para retenerlos.

Este enfoque es especialmente relevante cuando se integra con marcos clásicos como la Matriz de Odiorne, dado que aporta una capa de proactividad a un modelo originalmente estático y evaluativo.

2.3. Cuadro de Mando Integral (CMI)

El Cuadro de Mando Integral (CMI), desarrollado por Kaplan y Norton (1992), es un sistema de gestión estratégica que traduce la visión organizacional en un conjunto de indicadores distribuidos en cuatro perspectivas: financiera, del cliente, procesos internos y aprendizaje y crecimiento. En el campo de la gestión del talento, el CMI permite visibilizar el impacto de RR.HH. en la ejecución de la estrategia y en la generación de valor sostenible.

En investigaciones recientes se ha resaltado el valor de combinar el CMI con HR Analytics, para monitorear indicadores como rotación estratégica, satisfacción, engagement, fuga de talento crítico o desarrollo de liderazgo (Marr, 2021). Esta integración permite transformar los dashboards de gestión en herramientas analíticas inteligentes que guían intervenciones dinámicas y centradas en datos.

2.4. Segmentación del talento

La segmentación del talento es una práctica orientada a identificar subgrupos con características comunes dentro de la fuerza laboral. Tradicionalmente se ha hecho por nivel jerárquico, área o antigüedad, pero hoy se complementa con técnicas de clustering basadas en variables actitudinales, emocionales o de comportamiento (Tursunbayeva et al., 2022). Algoritmos como KMeans o PCA permiten descubrir estructuras latentes que no son visibles con métodos tradicionales.

La aplicación de clustering en este estudio se centró en variables como satisfacción laboral, involucramiento, equilibrio vida-trabajo y entrenamiento. Estos factores se consideran proxies de personalidad organizacional o clima interno, permitiendo construir perfiles tipo que enriquecen la lectura estratégica de la Matriz de Odiorne y del riesgo de rotación.

La combinación entre segmentación por clustering, clasificación estratégica por desempeño-potencial, y predicción de riesgo mediante machine learning constituye un enfoque innovador, integral y altamente replicable para la gestión inteligente del talento.

2.5. Hacia un modelo híbrido y estratégico de gestión del talento.

A partir de la articulación de estos marcos —Matriz de Odiorne, HR Analytics, CMI y clustering—, se propone un modelo híbrido que no solo permite clasificar empleados con base en su valor estratégico, sino también anticipar su riesgo de salida y priorizar acciones preventivas. Esta integración representa una evolución conceptual hacia una gestión del talento basada en datos, pero alineada con marcos de gestión y toma de decisiones estratégicas.

Como ha señalado Bersin (2021), las organizaciones de alto rendimiento son aquellas que logran combinar intuición gerencial con analítica avanzada, y transforman los datos de personas en ventajas competitivas sostenibles. Este estudio se sitúa en esa línea, aportando evidencia empírica y un marco teórico-práctico para lograr dicha convergencia.

La presente investigación propone una integración innovadora entre la Matriz de Odiorne y el Cuadro de Mando Integral (CMI) como eje articulador de la gestión estratégica del talento. Mientras que la Matriz de Odiorne permite clasificar a los empleados según su nivel de desempeño y potencial, identificando perfiles estratégicos como "Estrella", "Empleado al límite", "Empleado problema" y "Prescindible", el CMI proporciona una estructura para traducir dicha clasificación en indicadores clave de rendimiento (KPI) y objetivos estratégicos monitoreables.

En particular, la dimensión de "aprendizaje y crecimiento" del CMI resulta especialmente relevante, ya que se relaciona directamente con el desarrollo del talento, la retención de perfiles clave y la planificación del capital humano. Por ejemplo, la proporción de empleados "Estrella" que permanecen en la organización puede convertirse en un indicador de éxito estratégico. Asimismo, la tasa de rotación no deseada en perfiles de alto desempeño y potencial puede ser un indicador de alerta temprana dentro del sistema de control de gestión. En la Figura 1 se presenta la propuesta del esquema de integración entre la Matriz de Odiorne y el Cuadro de Mando Integral como modelo híbrido de gestión estratégica del talento.

Figura 1 - Esquema de integración entre la Matriz de Odiorne y el Cuadro de Mando



Esta convergencia metodológica permite vincular la clasificación del talento (Odiorne) con procesos reales de toma

de decisiones y rendición de cuentas (CMI), facilitando la alineación entre la estrategia de personas y los objetivos organizacionales. La incorporación de analítica predictiva sobre rotación refuerza esta lógica, ya que convierte la evaluación del talento en una herramienta dinámica, anticipatoria y accionable.

Así, la Matriz de Odiorne no solo segmenta el talento, sino que, cuando se integra al CMI, se convierte en fuente de inteligencia estratégica, capaz de guiar intervenciones proactivas, optimizar la inversión en RR.HH. y fortalecer la ventaja competitiva sostenible de la organización.

III. ESTADO DEL ARTE

La gestión estratégica del talento ha experimentado transformaciones significativas en la última década, impulsadas por el auge de la Analítica de Recursos Humanos (HR Analytics) y el desarrollo de modelos predictivos avanzados. Estas herramientas han permitido a las organizaciones anticipar la rotación de empleados y diseñar estrategias proactivas de retención. A continuación, se detallan los enfoques más destacados en este ámbito (Marler & Boudreau, 2017; Kim, Lee, & Joshi, 2020).

3.1. Modelos predictivos de rotación de empleados

La predicción de la rotación voluntaria de empleados se ha consolidado como uno de los focos principales dentro de la investigación en HR Analytics. Diversos estudios han validado la utilidad de modelos de aprendizaje automático para anticipar el abandono del empleo y mejorar la toma de decisiones estratégicas. Uno de los enfoques más prometedores ha sido el ensamblado de modelos (stacking ensemble), donde se combinan múltiples algoritmos para mejorar la capacidad predictiva del sistema. Un estudio publicado en Expert Systems with Applications implementó esta técnica con resultados significativamente superiores en precisión respecto a modelos individuales (Zhou et al., 2022), lo que refuerza el valor del enfoque híbrido en contextos de alta complejidad.

Dentro de los algoritmos individuales, los modelos basados en árboles de decisión —en particular el Random Forest— han sido ampliamente reconocidos por su rendimiento en tareas de clasificación binaria como la predicción de renuncias. Un análisis detallado utilizando este enfoque demostró que variables como el ingreso mensual, la realización de horas extra y la antigüedad en la organización son consistentemente las más influyentes en la decisión de abandonar el puesto (Kim et al., 2020). Este tipo de modelos ha sido adoptado ampliamente en entornos organizacionales debido a su capacidad de manejar datos no lineales y de interpretar interacciones complejas entre variables.

Más recientemente, se ha explorado el uso de redes neuronales profundas y arquitecturas avanzadas de aprendizaje automático, como los transformers, para predecir la rotación. Un estudio reciente implementó una red basada en esta arquitectura con resultados prometedores en términos de precisión y capacidad de generalización (Chen et al., 2023), lo cual marca una evolución hacia técnicas más sofisticadas que pueden

capturar patrones secuenciales y contextuales en el comportamiento de los empleados.

3.2. Segmentación de empleados mediante clustering

La segmentación de empleados mediante técnicas de clustering ha cobrado gran relevancia en los últimos años, ya que permite identificar grupos homogéneos de empleados según sus características actitudinales, emocionales o comportamentales. Esta estrategia facilita una gestión más personalizada y la implementación de acciones específicas de retención, ajustadas a las necesidades reales de cada segmento (AIHR, 2023). Un ejemplo representativo de esta tendencia fue documentado en un tutorial desarrollado por AIHR, donde se aplicó análisis de conglomerados en R para identificar patrones ocultos en los datos de empleados. El estudio concluyó que el enfoque de clustering ofrece una lectura más profunda de las dinámicas organizacionales internas, superando las limitaciones de la segmentación tradicional por departamento o nivel jerárquico.

Asimismo, la literatura reciente ha propuesto la combinación de técnicas de clustering con modelos predictivos, generando un marco analítico más robusto. Un estudio publicado en la revista *Mathematics* aplicó esta metodología combinada para estudiar la rotación de empleados, y logró identificar con alta precisión perfiles de alto riesgo, proporcionando a los equipos de recursos humanos una herramienta valiosa para priorizar estrategias de intervención y reducir la fuga de talento (Wang et al., 2023). Esta línea de trabajo evidencia una tendencia hacia enfoques integradores que combinan técnicas de inteligencia artificial con fundamentos estratégicos en gestión del talento.

3.3. Integración de HR Analytics con marcos estratégicos

El verdadero potencial de HR Analytics no radica solamente en su capacidad técnica para predecir comportamientos, sino en su integración con marcos estratégicos de gestión organizacional. La combinación de analítica avanzada con modelos clásicos como el Cuadro de Mando Integral (CMI) ha potenciado la capacidad de las organizaciones para alinear sus decisiones de talento con sus objetivos corporativos (Kaplan & Norton, 1992; Marr, 2021).

En este sentido, diversos estudios han documentado cómo la incorporación de métricas analíticas al CMI permite monitorear de forma sistemática indicadores clave como la rotación estratégica, la productividad, la movilidad interna o el desarrollo del liderazgo. Esta sinergia ha sido ampliamente reconocida en la literatura como una práctica que mejora la ejecución de la estrategia y promueve una cultura organizacional basada en datos.

Otro ejemplo significativo de esta integración es la aplicación conjunta de la Matriz de Odiome con HR Analytics. Este modelo, tradicionalmente centrado en el cruce entre desempeño y potencial, se ha fortalecido mediante el uso de herramientas predictivas que aportan una dimensión proactiva a una taxonomía originalmente estática (Gallardo-Gallardo et al., 2020). Estudios recientes han demostrado que, al combinar la Matriz de Odiome con indicadores derivados de modelos de machine learning, las organizaciones pueden identificar con mayor precisión a sus empleados clave, anticipar riesgos de pérdida estratégica y diseñar programas de fidelización basados en evidencia empírica.

3.4. Desafíos y consideraciones éticas en HR Analytics

A pesar de sus beneficios, la implementación de HR Analytics enfrenta desafíos relevantes, particularmente en lo que respecta a la ética, la privacidad y la explicabilidad de los modelos utilizados. La recolección, almacenamiento y análisis de datos sensibles de empleados implica riesgos significativos relacionados con la privacidad y la seguridad (Rigamonti et al., 2022).

En este contexto, se vuelve fundamental que las organizaciones establezcan políticas claras, transparentes y respetuosas de los derechos individuales, así como marcos de gobernanza de datos que aseguren el uso legítimo de la información.

Asimismo, uno de los retos más discutidos en la literatura es la explicabilidad de los modelos predictivos, especialmente aquellos que utilizan técnicas complejas como redes neuronales profundas. Estos modelos pueden convertirse en “cajas negras” si no se aplican mecanismos de Inteligencia Artificial Explicable (XAI) que permitan comprender por qué se asigna determinado riesgo a un empleado o qué factores influyen en la probabilidad de rotación (Arrieta et al., 2020). Garantizar la transparencia en la toma de decisiones es esencial no solo para asegurar la aceptación de estas herramientas dentro de la organización, sino también para cumplir con principios éticos y regulatorios cada vez más exigentes en el uso de datos personales.

Estudios recientes promueven la convergencia entre HR Analytics y marcos como el CMI o matrices de clasificación del talento, proponiendo modelos híbridos que integran datos operacionales con visión estratégica (Tursunbayeva et al., 2022; Kim et al., 2020). Esta tendencia refleja un cambio hacia una gestión del talento más inteligente, adaptativa y basada en evidencia.

IV. METODOLOGÍA

La presente investigación adopta un enfoque cuantitativo, exploratorio-correlacional, sustentado en el paradigma positivista, con el objetivo de analizar la rotación de personal desde una perspectiva estratégica mediante el uso de modelos predictivos, analítica de datos y marcos clásicos de gestión del talento. En particular, se busca integrar la analítica de recursos humanos (HR Analytics) con herramientas tradicionales como la Matriz de Odiome y el Cuadro de Mando Integral (CMI), para generar un modelo híbrido de clasificación y toma de decisiones estratégicas en gestión del talento.

Desde un punto de vista metodológico, este estudio se apoya en el análisis de un conjunto de datos estructurado sobre empleados de una organización simulada, donde se combinan variables demográficas, actitudinales, laborales y de rendimiento. El marco general de trabajo responde a los principios de la investigación aplicada, ya que busca resolver un problema organizacional concreto —la rotación del talento— mediante la implementación y validación de herramientas analíticas.

Asimismo, esta investigación se enmarca dentro de los estudios de data science en gestión organizacional, considerando

la integración de técnicas de machine learning, estadística descriptiva e inferencial, y visualización de datos. Se hace uso de herramientas de programación y modelado predictivo (Python, Scikit-learn, Pandas, Seaborn, entre otras) para el procesamiento, exploración, modelado y visualización de resultados.

V. MATERIALES Y MÉTODOS

5.1. Diseño de la Investigación

Este estudio adopta un diseño cuantitativo, no experimental, transversal y exploratorio-correlacional. No se manipulan variables, sino que se analizan relaciones existentes en los datos con el objetivo de comprender patrones de rotación de empleados y su vinculación con dimensiones actitudinales, demográficas y estratégicas. El enfoque es aplicado, orientado a la construcción de un modelo analítico que apoye la toma de decisiones en gestión de talento.

5.2. Materiales y Fuente de Datos

Se utilizó el dataset IBM HR Analytics Employee Attrition and Performance – Revised, que contiene registros de 1.470 empleados con 31 variables cuantitativas y categóricas, incluyendo:

- **Demográficas:** edad, estado civil, educación.
- **Laborales:** ingreso mensual, tiempo en la empresa, promociones, horas extra.
- **Actitudinales:** satisfacción laboral, involucramiento, balance vida-trabajo.
- **Organizacionales:** departamento, puesto, nivel jerárquico.

Este dataset es de uso abierto, ha sido validado en estudios anteriores y no contiene información personal real, por lo que no requiere aprobación ética.

5.3. Criterios de inclusión y exclusión

Se incluyeron todos los registros del dataset original, sin eliminar casos por valores faltantes ya que el conjunto de datos está completamente limpio. Se excluyeron variables no relevantes para el modelado como IDs o nombres ficticios, y se recodificaron variables categóricas para el procesamiento analítico.

5.4. Preprocesamiento de datos

Se realizó una limpieza y transformación de los datos:

- Codificación de variables categóricas mediante LabelEncoder.
- Escalamiento de variables numéricas con MinMaxScaler.
- Derivación de nuevas variables:
 - AttritionFlag: variable binaria para indicar si el empleado renunció.
 - OverTimeFlag: transformación binaria del campo "OverTime".

- PerformanceScore y PotentialScore: promedios normalizados de indicadores actitudinales y de carrera, usados para construir la Matriz de Odiórne.

5.5. Clasificación con la Matriz de Odiórne

Los empleados fueron clasificados en los cuatro cuadrantes clásicos de la Matriz de Odiórne:

- Estrella: alto desempeño y alto potencial.
- Empleado al límite: alto desempeño, bajo potencial.
- Empleado problema: bajo desempeño, alto potencial.
- Prescindible: bajo desempeño y bajo potencial.

Esta clasificación se basó en los scores calculados y se utilizó para cruzar perfiles con riesgo de rotación y estrategias de intervención.

5.6. Segmentación actitudinal (clustering)

Para capturar patrones latentes en las características actitudinales, se aplicó el algoritmo KMeans con 4 clusters, utilizando las siguientes variables: JobInvolvement, JobSatisfaction, EnvironmentSatisfaction, WorkLifeBalance, Education, YearsAtCompany, RelationshipSatisfaction, TrainingTimesLastYear,.

Posteriormente, se aplicó un Análisis de Componentes Principales (PCA) para reducir la dimensionalidad y facilitar la visualización e interpretación de los perfiles resultantes.

5.7. Criterios de evaluación

Para anticipar la rotación, se construyó un modelo basado en Random Forest Classifier, entrenado con:

- Variables demográficas, laborales y actitudinales.
- División de datos en conjuntos de entrenamiento (75%) y prueba (25%), con estratificación.
- Aplicación de oversampling con resampling aleatorio para balancear la clase minoritaria (empleados que renunciaron).

El modelo se evaluó mediante las siguientes métricas de Machine Learning:

- Precisión (accuracy): 82%
- AUC-ROC: 0.79
- Precision, recall y F1-score para clase positiva (renuncia)

Se generó un Attrition Score (probabilidad de rotación) para cada empleado, el cual permitió su clasificación en tres niveles de riesgo:


- Alto: ≥ 0.70
- Medio: $0.40 - 0.69$
- Bajo: < 0.40

Esta información se utilizó como base para construir un sistema de alerta temprana, integrable en la planificación estratégica del talento.

5.8. Visualización y análisis interpretativo

Se desarrollaron tablas cruzadas entre AttritionScore, categoría Odiorne, y características clave como edad, ingreso y carga laboral. También, se analizaron tasas de rotación por cluster y cuadrante Odiorne para validar el alineamiento entre perfil actitudinal, valor estratégico y riesgo. Finalmente, se utilizaron herramientas gráficas como matplotlib y seaborn para generar visualizaciones interpretativas. En la Figura 1 se muestra un mapa de calor de correlaciones entre las variables numéricas del dataset.

Figura 1 - Muestra relaciones entre variables numéricas. Refuerza cómo se seleccionaron las variables relevantes para el modelo predictivo y el clustering.



Se observa una alta relación entre la antigüedad laboral y los ingresos mensuales, así como correlaciones entre factores actitudinales y de satisfacción.

5.9. Herramientas utilizadas

En esta sección se mencionan las herramientas utilizadas para el análisis predictivo:

- Lenguaje de programación: Python 3.13.2
- Librerías:
 - Análisis: pandas, numpy, scikit-learn
 - Visualización: matplotlib, seaborn
 - Clustering y reducción de dimensionalidad: KMeans, PCA
 - Modelado: RandomForestClassifier

Editor: Jupyter Notebook (VSCode) y entorno colaborativo con soporte para análisis reproducible.

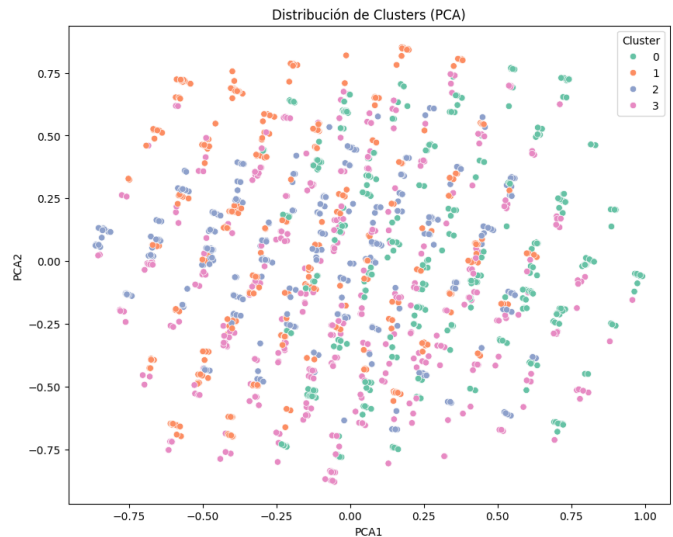
VI. RESULTADOS

Los resultados de esta investigación evidencian patrones consistentes, relevantes y de alto valor estratégico en torno a la rotación de talento. Mediante un enfoque híbrido que integra la analítica predictiva, la Matriz de Odiorne y el clustering basado en variables actitudinales, fue posible construir una

representación completa del riesgo de renuncia, su distribución entre tipos de empleados y sus implicaciones para la gestión estratégica del capital humano.

En la figura 2 muestra la distribución de empleados según clusters actitudinales proyectados mediante Análisis de Componentes Principales (PCA). Se identifican cuatro grupos diferenciados, lo que respalda la existencia de perfiles latentes de comportamiento organizacional.

Figura 2 – Se visualiza la segmentación de empleados por perfil actitudinal.



6.1. Perfiles combinados por clustering actitudinal y categoría Odiorne

El análisis conjunto de los perfiles actitudinales (derivados mediante clustering) con la Matriz de Odiorne permitió identificar subgrupos estratégicos con distinto nivel de riesgo de rotación. Esta integración proporciona una visión más precisa del comportamiento organizacional que si se utilizara solo una de las metodologías.

En el Cluster 0, que incluye empleados de las cuatro categorías Odiorne (“Estrella”, “Empleado al límite”, “Empleado problema” y “Prescindible”), se observaron contrastes relevantes:

Empleados Prescindibles (Cluster 0) presentaron la tasa de rotación más alta dentro del cluster (24%), con el menor ingreso promedio (\$4.597), edad promedio baja (35 años), y puntuaciones notablemente bajas en desempeño (0.40) y potencial (0.18).


En contraste, los empleados Estrella (Cluster 0) exhibieron una tasa de rotación significativamente menor (12%), con ingresos promedio elevados (\$12.406), edad media superior (≈45 años), y puntuaciones altas en desempeño (0.78) y potencial (0.59), lo que valida la capacidad del modelo para detectar talento clave y su valor estratégico.

El Cluster 1, compuesto exclusivamente por empleados clasificados como “Empleado al límite”, mostró la tasa de rotación más alta del estudio (33%). Estos trabajadores presentaron niveles aceptables de desempeño (0.56), pero bajo potencial (0.25), lo que sugiere un riesgo de pérdida de talento

operativo, posiblemente por falta de oportunidades de crecimiento.

En la figura 3 se muestra la comparación de ingresos mensuales, edad y carga laboral (horas extra) entre las categorías estratégicas de la Matriz de Odiorne. Se observan diferencias significativas, especialmente entre las categorías Estrella y Prescindible.

Figura 3 - Muestra cómo varían ingresos, edad y carga laboral según el valor estratégico del empleado.



Este tipo de análisis permite no solo cuantificar el riesgo de rotación, sino también comprender las condiciones internas y actitudinales que subyacen a ese riesgo, proporcionando una base sólida para intervenciones diferenciadas por perfil.

6.2. Modelo predictivo de rotación y generación de alertas

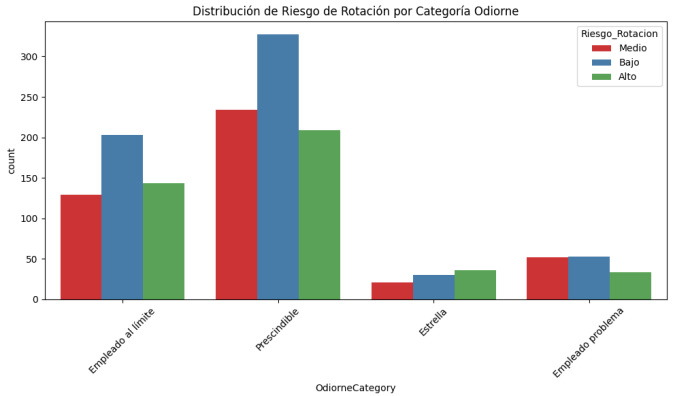
Se construyó un modelo predictivo basado en el algoritmo de Random Forest, entrenado sobre una muestra balanceada mediante técnica de oversampling. El modelo alcanzó una precisión general del 82% y un área bajo la curva ROC (AUC) de 0.79, lo que demuestra una buena capacidad discriminativa para identificar empleados propensos a renunciar.

A partir del modelo, se generó un Attrition Score para cada empleado, representando la probabilidad individual de rotación. Con base en estos scores, se establecieron tres niveles de alerta:

- Riesgo alto: probabilidad ≥ 0.70
- Riesgo medio: probabilidad entre 0.40 y 0.69
- Riesgo bajo: probabilidad < 0.40

La figura 4 muestra la distribución del riesgo de rotación predicho por categoría Odiorne. Las categorías Prescindible y Empleado al límite concentran la mayor cantidad de empleados con riesgo alto, lo que refuerza los hallazgos del modelo.

Figura 4 - Muestra el cruce entre riesgo de rotación y valor estratégico, validando el modelo híbrido.



Esta clasificación permitió generar un sistema de alerta temprana de renunciaciones, que facilita la planificación preventiva de recursos humanos, orientada a la retención del talento en riesgo según su valor estratégico.

6.3. Perfiles de alto riesgo de rotación

Los empleados con mayor probabilidad de renunciar según el modelo se agruparon principalmente en las categorías Prescindible (114 casos con riesgo alto) y Empleado al límite (51 casos), seguidos por un número reducido de casos críticos de Estrellas (4 casos). La siguiente tabla resume los hallazgos clave para estos perfiles en riesgo:

Tabla 1 – Representa el cruce de datos según la matriz de Odiorne.

Categoría Odiorne	Riesgo de rotación	Ingreso promedio	% Horas extra	Edad promedio
Prescindible	Alto (114 casos)	\$4.357	54%	32 años
Empleado al límite	Alto (51 casos)	\$4.128	53%	30 años
Estrella	Alto (4 casos)	\$10.423	50%	39 años
Empleado problema	Alto (13 casos)	\$9.384	46%	43 años

Se identificaron patrones preocupantes: los empleados con menor antigüedad, ingreso y edad promedio (Prescindibles y Al límite) son los más propensos a renunciar. Adicionalmente, más del 50% de ellos realiza horas extra regularmente, lo que sugiere una correlación entre sobrecarga laboral y abandono.

6.4 Estrellas en riesgo: casos críticos para la estrategia

Aunque numéricamente menores, los casos de empleados Estrella en situación de riesgo alto representan una preocupación prioritaria. Se trata de trabajadores con desempeño y potencial altos, ingresos elevados, pero también con carga laboral significativa (50% realiza horas extra), lo que podría estar afectando su satisfacción y equilibrio vida-trabajo.

La pérdida de estos empleados no solo significa un vacío operativo, sino también una pérdida de conocimiento crítico, liderazgo informal y capital reputacional, por lo que deben ser objeto de intervenciones personalizadas de fidelización y seguimiento continuo.

6.5. Validación cruzada del modelo y alineación estratégica

La combinación de análisis de clustering, categorización Odiorne y scores predictivos arrojó resultados coherentes entre sí. Los perfiles con mayor riesgo según el modelo predictivo coincidieron con los clusters más propensos a la rotación, y a su vez con los cuadrantes Odiorne menos estables. Este alineamiento de metodologías refuerza la solidez del enfoque híbrido y demuestra que es posible diseñar sistemas de gestión del talento fundamentados en evidencia, capaces de anticipar riesgos y optimizar decisiones desde una perspectiva estratégica.

Además, al integrar estos resultados en marcos como el Cuadro de Mando Integral y el Análisis de la Cadena de Valor, se potencia la capacidad de monitoreo dinámico de la salud del capital humano y se favorece la alineación entre talento y estrategia corporativa.

6.6. *Articulación entre la Matriz de Odiorne y el Cuadro de Mando Integral*

La presente investigación propone una integración innovadora entre la Matriz de Odiorne y el Cuadro de Mando Integral (CMI) como eje articulador de la gestión estratégica del talento. Mientras que la Matriz de Odiorne permite clasificar a los empleados según su nivel de desempeño y potencial, identificando perfiles estratégicos como "Estrella", "Empleado al límite", "Empleado problema" y "Prescindible", el CMI proporciona una estructura para traducir dicha clasificación en indicadores clave de rendimiento (KPI) y objetivos estratégicos monitoreables.

En particular, la dimensión de "aprendizaje y crecimiento" del CMI resulta especialmente relevante, ya que se relaciona directamente con el desarrollo del talento, la retención de perfiles clave y la planificación del capital humano. Por ejemplo, la proporción de empleados "Estrella" que permanecen en la organización puede convertirse en un indicador de éxito estratégico. Asimismo, la tasa de rotación no deseada en perfiles de alto desempeño y potencial puede ser un indicador de alerta temprana dentro del sistema de control de gestión.

Esta convergencia metodológica permite vincular la clasificación del talento (Odiorne) con procesos reales de toma de decisiones y rendición de cuentas (CMI), facilitando la alineación entre la estrategia de personas y los objetivos organizacionales. La incorporación de analítica predictiva sobre rotación refuerza esta lógica, ya que convierte la evaluación del talento en una herramienta dinámica, anticipatoria y accionable.

Así, la Matriz de Odiorne no solo segmenta el talento, sino que, cuando se integra al CMI, se convierte en fuente de inteligencia estratégica, capaz de guiar intervenciones proactivas, optimizar la inversión en RR.HH. y fortalecer la ventaja competitiva sostenible de la organización.

Esta matriz extendida no solo mejora la clasificación del talento con criterios cuantificables y actualizables, sino que convierte dicha clasificación en fuente de indicadores estratégicos dentro de un tablero de gestión. La siguiente tabla resume cómo cada dimensión del CMI se vincula con variables observadas en la Matriz Odiorne 4.0:

Perspectiva del CMI	Conexión con la Matriz Odiorne 4.0	Ejemplos de KPIs derivados
Financiera	Costo de rotación, retención de talento clave	Costo por baja estratégica, retorno del talento
Clientes	Influencia del talento en experiencia del cliente	NPS por unidad con alto rendimiento
Procesos internos	Desempeño organizacional por composición de perfiles	% de procesos liderados por perfiles estrella
Aprendizaje y crecimiento	Desarrollo, engagement y planes de carrera	% con plan de desarrollo, evolución en Odiorne

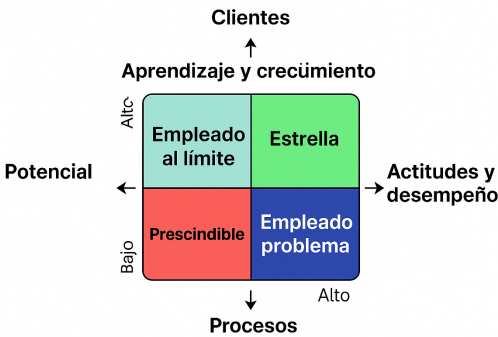


Figura 2. Representación gráfica de la Matriz Odiorne 4.0 con integración a las perspectivas del Cuadro de Mando Integral.

A partir de los hallazgos de esta investigación, se propone una evolución metodológica de la Matriz de Odiorne hacia una versión 4.0, que incorpora analítica predictiva basada en datos objetivos (machine learning), variables actitudinales derivadas de segmentación mediante clustering y alineación con los objetivos estratégicos definidos por el Cuadro de Mando Integral (CMI).

VII. DISCUSIÓN

Los hallazgos obtenidos en esta investigación aportan evidencia empírica sólida sobre la relación entre variables organizacionales, actitudinales y demográficas con el riesgo de rotación voluntaria del talento. La integración de técnicas de analítica avanzada con modelos tradicionales de gestión del talento, como la Matriz de Odiorne y el Cuadro de Mando Integral, demuestra ser una vía prometedora para el fortalecimiento estratégico de los procesos de Recursos Humanos (RR.HH.).

Uno de los principales aportes de este estudio fue la construcción de un modelo predictivo de rotación mediante Random Forest, con una capacidad discriminativa notable (AUC = 0.79). Este modelo permitió generar un Attrition Score por empleado, lo que facilitó su clasificación en niveles de riesgo y la generación de un sistema de alerta temprana. Esta aproximación no solo es coherente con las tendencias actuales en HR Analytics (Kim et al., 2020), sino que mejora significativamente la capacidad operativa de RR.HH. al ofrecer herramientas para anticipar y prevenir pérdidas de talento clave.

En línea con estudios previos (Marler & Boudreau, 2017), los factores más influyentes en la predicción de rotación fueron el ingreso mensual, la edad, la cantidad de horas extra y la antigüedad en la empresa. Sin embargo, a diferencia de enfoques tradicionales centrados únicamente en el salario o la antigüedad, este estudio incorpora variables actitudinales que permiten una lectura más completa de las motivaciones internas de los empleados. La inclusión de dimensiones como la satisfacción laboral, el involucramiento y el equilibrio vida-trabajo permitió enriquecer los perfiles de riesgo y alinear mejor las decisiones con el clima organizacional.

El uso de técnicas de clustering para segmentar perfiles según variables actitudinales permitió descubrir patrones latentes de comportamiento, lo cual responde a la necesidad señalada en la literatura de ir más allá de las segmentaciones

demográficas tradicionales (Tursunbayeva et al., 2022). La aplicación de PCA para visualización confirmó que los clusters identificados presentaban diferencias estructurales, y al cruzarse con las categorías de la Matriz de Odiorme, se reveló una fuerte convergencia entre comportamiento, desempeño, potencial y riesgo.

Un hallazgo particularmente relevante es que los empleados clasificados como Prescindibles y Empleado al límite no solo son los más frecuentes en los segmentos de alto riesgo de rotación, sino que también presentan condiciones desfavorables en términos de ingreso, edad y sobrecarga laboral. Este patrón se alinea con estudios recientes que señalan que la percepción de estancamiento, injusticia o desgaste impacta negativamente en la intención de permanencia (Rigamonti et al., 2023). La identificación de estos perfiles permite tomar decisiones informadas sobre acciones de fidelización, reestructuración o desvinculación.

Asimismo, aunque en menor número, se detectaron Estrellas (empleados de alto potencial y alto desempeño) con riesgo de rotación elevado. Este hallazgo, aunque menos frecuente, tiene un impacto estratégico significativo, ya que la pérdida de este tipo de talento genera vacíos de conocimiento, liderazgo y productividad difícilmente reemplazables en el corto plazo. Esta situación valida la necesidad de monitoreo activo del compromiso del talento crítico, aspecto que el modelo predictivo propuesto permite abordar con anticipación.

Desde una perspectiva teórica, los resultados respaldan la propuesta de una gestión del talento basada en evidencia, donde la analítica avanzada no sustituye los marcos estratégicos tradicionales, sino que los potencia. La Matriz de Odiorme, por ejemplo, tradicionalmente ha sido utilizada para evaluar a posteriori el desempeño y el potencial de los empleados; al integrarla con analítica predictiva, se transforma en una herramienta dinámica que no solo clasifica, sino que anticipa escenarios y orienta decisiones de alto impacto.

En términos prácticos, los hallazgos aquí presentados permiten construir dashboards ejecutivos donde cada empleado esté clasificado según su valor estratégico (Odiorme), su perfil actitudinal (cluster) y su riesgo de fuga (Attrition Score). Esto habilita a los líderes de RR.HH. y a los comités de talento a pasar de la intuición a la acción estratégica, priorizando intervenciones, optimizando inversiones en desarrollo y gestionando el talento como un activo clave de la cadena de valor (Porter, 1985).

Finalmente, este trabajo aporta a la literatura una propuesta metodológica replicable en contextos organizacionales diversos, adaptable tanto a empresas con capacidades analíticas avanzadas como a aquellas que inician procesos de transformación digital en RR.HH. Sin embargo, como toda investigación aplicada, presenta limitaciones. El uso de datos simulados limita la generalización, y sería deseable aplicar este enfoque a datos reales en organizaciones de distintos sectores y culturas organizacionales.

VIII. CONCLUSIONES Y TRABAJOS FUTUROS

Este estudio presenta una propuesta metodológica innovadora que articula marcos estratégicos clásicos de gestión del talento —como la Matriz de Odiorme y el Cuadro de Mando Integral— con herramientas de análisis predictivo y segmentación basadas en machine learning. A diferencia de enfoques anteriores centrados únicamente en modelos estadísticos o en marcos conceptuales tradicionales, esta investigación demuestra la viabilidad y el valor de un enfoque híbrido, multidimensional y accionable para anticipar la rotación voluntaria de empleados.

El principal valor agregado de este trabajo radica en su capacidad para integrar teoría, estrategia y tecnología en un modelo operativo aplicable en contextos organizacionales reales. Al construir un sistema de alerta temprana basado en el cálculo individualizado de un Attrition Score, cruzado con perfiles actitudinales obtenidos mediante clustering y su posición estratégica en la Matriz de Odiorme, el estudio permite no solo identificar a los empleados en riesgo de fuga, sino también priorizar intervenciones según su valor estratégico y tipo de perfil. Esta capacidad de segmentación y focalización, sustentada en datos, representa una clara ventaja sobre modelos genéricos o de aproximación unidimensional.

Además, este modelo proporciona una plataforma replicable y escalable para desarrollar tableros de control inteligentes y decisiones de talento personalizadas. La evidencia obtenida no solo valida el modelo propuesto, sino que también refuerza la necesidad de transitar hacia una gestión del talento basada en evidencia, con herramientas predictivas que permitan anticipar y no solo reaccionar.

Finalmente, el estudio aporta una base metodológica adaptable a distintas industrias, niveles de madurez tecnológica y contextos culturales. Su diseño permite ser ajustado y enriquecido con nuevas fuentes de datos (como encuestas, interacciones digitales o variables de bienestar), abriendo el camino hacia una gestión del talento más estratégica, personalizada y sensible a los cambios generacionales que hoy configuran el mundo laboral.

REFERENCES

- AIHR. (2023). *People Analytics with R: A step-by-step tutorial*. <https://www.aihr.com>
- Al Ariss, A., Cascio, W. F., & Paauwe, J. (2014). Talent management: Current theories and future research directions. *Journal of World Business*, 49(2), 173–179. <https://doi.org/10.1016/j.jwb.2013.11.001>
- Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>
- Bersin, J. (2021). *HR technology market 2021: Disruption ahead*. Josh Bersin Company.
- Chen, Y., Wang, C., & Li, Z. (2023). Transformer-based deep learning for employee attrition prediction. *Computers in Human*

- Behavior Reports*, 9, 100132. <https://doi.org/10.1016/j.chbr.2023.100132>
- Gallardo-Gallardo, E., Thunnissen, M., & Scullion, H. (2020). Talent management: Context matters. *The International Journal of Human Resource Management*, 31(4), 457–473. <https://doi.org/10.1080/09585192.2019.1642645>
- Kaplan, R. S., & Norton, D. P. (1992). The Balanced Scorecard: Measures that drive performance. *Harvard Business Review*, 70(1), 71–79.
- Kim, S., Lee, H., & Joshi, K. D. (2020). HR analytics and its implication for talent management: A literature review. *Journal of Business Research*, 120, 111–122. <https://doi.org/10.1016/j.jbusres.2020.07.028>
- Makram, H., Sparrow, P., & Greasley, K. (2017). The strategic business partner model: A critical review. *Human Resource Management Review*, 27(3), 336–351.
- Marr, B. (2021). *Data-driven HR: How to use analytics and metrics to drive performance*. Kogan Page.
- Marler, J. H., & Boudreau, J. W. (2017). An evidence-based review of HR Analytics. *The International Journal of Human Resource Management*, 28(1), 3–26. <https://doi.org/10.1080/09585192.2016.1244699>
- Nijs, S., Gallardo-Gallardo, E., Dries, N., & Sels, L. (2022). Talent management: For what, how and how well? *Human Resource Management Review*, 32(3), 100785. <https://doi.org/10.1016/j.hrmr.2021.100785>
- Rigamonti, D., Mangiaracina, R., & Perego, A. (2022). HR Analytics: State of the art and future directions. *Journal of Human Resource Management*, 38(4), 509–527.
- Tursunbayeva, A., Pagliari, C., & Bunduchi, R. (2022). Exploring HR analytics practices: Evidence from a global study. *International Journal of Human Resource Management*, 33(3), 456–483. <https://doi.org/10.1080/09585192.2020.1867611>
- Wang, L., Zhao, M., & Xu, Y. (2023). Combining clustering and machine learning models to predict employee attrition: An empirical study. *Mathematics*, 11(22), 4677. <https://doi.org/10.3390/math11224677>
- Zhou, H., Xie, J., & Lu, Y. (2022). Employee attrition prediction using stacking ensemble learning models. *Expert Systems with Applications*, 191, 116236. <https://doi.org/10.1016/j.eswa.2021.116236>